

HOCHSCHULE HANNOVER
HSH AKADEMIE

IntoCode & InterGeeks

Deep Learning

EINFÜHRUNG IN DIE KÜNSTLICHEN NEURONALEN NETZE

M.SC. BILAL AL HOMSI

HANNOVER, DEN 17.03.2025

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

- Deep Learning ist ein **überwachtes** Lernverfahren.
- Deep Learning kann Filter automatisch aus den Daten extrahieren und erlernen, ohne dass diese manuell definiert werden müssen.
- Deep Learning spezialisiert sich unter anderem auf folgende Aufgaben:
 - **Klassifikation**
 - **Loaklisierung**
 - **Objekterkennung**
 - **Bildsegmentierung:**
 - ◇ **Semantische** Segmentierung
 - ◇ **Instanzen**-Segmentierung

Computer-Vision-Aufgaben




Figure: Beispiel für Aufgaben in Computer Vision, **Quelle**.

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

Klassifikation

- Die Klassifikation ist eine grundlegende Aufgabe der Bildverarbeitung.
- Dabei wird ein Eingabebild einer bestimmten Klasse zugeordnet.
- Ein künstliches neuronales Netz kann trainiert werden, neue Datenpunkte präzise zu klassifizieren.
- Man unterscheidet zwei Arten der Klassifikation:
 - **Binäre Klassifikation:** Zuordnung zu einer von zwei möglichen Klassen.
 - **Mehrklassige Klassifikation:** Zuordnung zu einer von mehreren möglichen Klassen.
- Der Trainingsprozess umfasst folgende Schritte:
 - Aufbereitung und Einspeisung der Trainingsdaten in das Modell.
 - Das Modell lernt aus den gelabelten Daten relevante Merkmale, um unbekannte Daten korrekt zu klassifizieren.
 - Evaluation und Test des trainierten Modells mit neuen, bisher unbekannten Daten.

Bildklassifizierung



Figure: Beispiel für Bildklassifikation, **Quelle**.

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

Lokalisierung

- Die Lokalisierung ist die Aufgabe, ein Objekt in einem Bild zu identifizieren und dessen Position zu bestimmen.
- Sie gehört zu den zentralen Aufgaben der Bildverarbeitung.
- Ein künstliches neuronales Netz kann darauf trainiert werden, Objekte in Bildern präzise zu lokalisieren.
- Dabei werden die Koordinaten sogenannter **Bounding Box** (Begrenzungsrahmen) ermittelt, die das gesuchte Objekt umschließt.

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

Objekterkennung

- Die Objekterkennung umfasst das Finden und Klassifizieren von Objekten in einem Bild.
- Sie gehört zu den zentralen Aufgaben der Bildverarbeitung.
- Ein künstliches neuronales Netz kann darauf trainiert werden, Objekte in Bildern zuverlässig zu erkennen.
- Dabei werden sowohl die Klassenzugehörigkeit als auch die exakten Koordinaten der erkannten Objekte bestimmt.
- Die Objekterkennung kombiniert die Techniken der **Lokalisierung** und **Klassifikation**.

Objekterkennung




Figure: Beispiel für Objekterkennung, **Quelle**.

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

Bildsegmentierung

- Die Bildsegmentierung ist die Aufgabe, ein Bild in verschiedene Regionen oder Objekte zu unterteilen.
- Sie gehört zu den zentralen Aufgaben der Bildverarbeitung.
- Ein künstliches neuronales Netz kann darauf trainiert werden, sowohl Bilder in verschiedene Regionen als auch einzelne Objekte präzise zu segmentieren.
- Es gibt zwei Hauptarten der Bildsegmentierung:
 - **Semantische Segmentierung:** Alle Objekte derselben Klasse werden als eine zusammenhängende Region betrachtet.
 - **Instanzsegmentierung:** Jedes Objekt einer Klasse wird als separate Instanz erkannt und segmentiert.

Bildsegmentierung





Figure: Beispiel für Bildsegmentierung, UltralyticQuelle.


Vergleich zwischen Bildklassifizierung, semantischer Segmentierung und Instanzsegmentierung. **Quelle**




Image Recognition



Semantic Segmentation



Object Detection



Instance Segmentation

Bildverarbeitung

Arten von Features:

- **Low level Features:**

- Pixelwerte bzw. Farbinformationen
- Kanten und Ecken
- Texturen

- **Mid level Features:**

- Formen
- Muster
- Strukturen

- **High level Features:**

- Objekte
- Zusammenhänge

- **Features** sind Bildmerkmale, die Objekte und deren Strukturen in Bildern beschreiben.
- Künstliche Neuronale Netze können diese Merkmale automatisch extrahieren und erlernen.

Beispiel für Features in der Bildverarbeitung




Figure: Beispiel für Features in der Bildverarbeitung, **Quelle.**

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

Deep Learning

- Deep Learning ist ein Teilbereich des maschinellen Lernens und basiert auf Künstlichen Neuronalen Netzen.
- Für das Training eines Künstlichen Neuronalen Netzes werden folgende Komponenten benötigt:
 - **Qualitativer Datensatz:**
 - ◇ Der Datensatz muss **umfangreich**, **vielfältig** und von hoher **Varianz** sein.
 - **Geeignete Architektur des Neuronalen Netzes:**
 - ◇ Die Architektur hängt von der Aufgabenstellung ab – je komplexer sie ist, desto leistungsfähiger kann das Modell sein.
 - **Leistungsstarke Hardware für das Training:**
 - ◇ Training auf einer **CPU** ist langsam.
 - ◇ Training auf einer **GPU** ist schneller.
 - ◇ Training auf einer **TPU** ist am schnellsten.

Datensatz

- Um eine hohe **Genauigkeit** mit neuronalen Netzen zu erreichen, muss der Datensatz möglichst alle relevanten Fälle des gegebenen Problems abdecken.
 - **Umfangreich:**
 - ◇ Ein großer Datensatz verbessert das Lernen des Modells – je mehr Daten, desto besser die Generalisierung.
 - **Vielfältig:**
 - ◇ Der Datensatz sollte möglichst viele unterschiedliche Szenarien enthalten, damit das Modell verallgemeinern kann.
 - **Hohe Varianz:**
 - ◇ Eine große Varianz verhindert, dass das Modell nur bestimmte Muster lernt und sich zu stark darauf spezialisiert.
 - **Ausgewogene Klassenverteilung:**
 - ◇ Die verschiedenen Klassen sollten im Datensatz möglichst gleichmäßig verteilt sein, um eine Verzerrung des Modells zu vermeiden.

- Daten sind eine der wichtigsten Ressourcen für das Training Künstlicher Neuronaler Netze.
- Es gilt: “Die Qualität der Daten bestimmt die Qualität des Modells.”
- Doch wie kann man an geeignete Daten gelangen?
 - Die Wahl der Daten hängt stark von der Aufgabenstellung ab. Mögliche Quellen sind:
 - ◇ **Eigene Datenerhebung und Vorverarbeitung**
 - ◇ **Gekaufte Datensätze**
 - ◇ **Open-Source-Datensätze**
 - ◇ **Weitere Quellen je nach Anwendungsfall**

Augmentation

- Augmentation ist eine Technik, die in neuronalen Netzen verwendet wird, um künstliche Variationen von Trainingsdaten zu erzeugen.
- Typische Augmentationsmethoden sind zufällige Änderungen wie:
 - **Drehen**
 - **Spiegeln**
 - **Skalieren**
 - **Zuschneiden**
 - **Änderung der Helligkeit**
 - **Änderung des Kontrasts**
 - **Zoomen** (Hinein- und Herauszoomen)
- Durch Augmentation wird die Vielfalt des Datensatzes erhöht, wodurch das Modell robuster und generalisierungsfähiger wird.

Beispiel für augmentierte Bilddaten




Figure: Beispiel für Augmentation, Quelle.

Das Perzeptron

- Das Perzeptron ist die einfachste Form eines künstlichen Neurons.
- Die Eingabewerte werden mit zufällig initialisierten Gewichten multipliziert und anschließend summiert.
- Die mathematische Funktion des Perzeptrons lautet:

$$y = f \left(\sum_{i=1}^n w_i \cdot x_i + b \right)$$

- Das Perzeptron kann nur lineare Probleme lösen und wird für binäre Klassifikationen eingesetzt.




Figure: Das Perzeptron, Quelle.

Das Perzeptron




Figure: Das Perzeptron, Eigene Darstellung.

Einfaches Künstliches Neuronales Netz

- Ein einfaches Künstliches Neuronales Netz besteht aus drei Schichten:
 - **Eingabeschicht**
 - **Versteckte Schichten**
 - **Ausgabeschicht**
- Die Anzahl der versteckten Schichten kann variieren und bestimmt die Tiefe des Neuronalen Netzes.
- Jede Schicht kann eine beliebige Anzahl von Neuronen enthalten, wodurch die **Komplexität** des Netzwerks beeinflusst wird.




Figure: Einfaches Modell, **Eigene Darstellung.**

Eingabeschicht

- Die Eingabeschicht enthält so viele Neuronen wie Eingabewerte.
- Beispiel: Ein Bild mit der Größe **28 × 28** Pixel erfordert eine Eingabeschicht mit **784** Neuronen, wobei jedes Neuron einen Pixelwert repräsentiert.





Figure: Farbinformationen eines Bildes, **Quelle**.

Darstellung eines Bildes als Matrix



157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

Figure: Matrix der Pixelwerte eines Bildes, **Quelle**.

Ausgabeschicht

- Die Ausgabeschicht enthält so viele Neuronen, wie es Zielklassen gibt.
- Beispiel: Bei **10** Klassen, in die ein Bild klassifiziert werden soll, benötigt die Ausgabeschicht **10** Neuronen – jedes Neuron repräsentiert eine Klasse.




Figure: Ausgabe des KNNs, Quelle.

Ein tiefes Künstliches Neuronales Netz




Figure: Ein tiefes KNN, Eigene Darstellung.

Playground Tensorflow




Figure: Tensorflow Playground, Quelle.

Overfitting, Underfitting und Optimale Balance

- **Overfitting:** Das neuronale Netz passt sich zu stark an die Trainingsdaten an.
 - Es erzielt sehr gute Ergebnisse auf den Trainingsdaten, aber schlechte auf den Testdaten.
 - Das Modell hat die Merkmale der Trainingsdaten **auswendig gelernt** und kann nicht generalisieren.




Figure: Overfitting, Underfitting, Quelle.

Overfitting, Underfitting und Optimale Balance

- **Underfitting:** Das neuronale Netz hat die relevanten Merkmale aus den Daten nicht gelernt.
 - Sowohl auf Trainings- als auch auf Testdaten erzielt das Modell schlechte Ergebnisse.
 - Das Modell ist zu einfach oder unzureichend trainiert, sodass es weder klassifizieren noch generalisieren kann.




Figure: Overfitting, Underfitting, Quelle.

Overfitting, Underfitting und Optimale Balance

- **Optimale Balance:** Das neuronale Netz hat ausreichend Merkmale aus den Daten gelernt, ohne sie auswendig zu lernen.
 - Das Modell erzielt gute Ergebnisse sowohl auf den Trainings- als auch auf den Testdaten.
 - Es kann die gelernten Merkmale verallgemeinern und unbekannte Daten zuverlässig klassifizieren.




Figure: Overfitting, Underfitting, Quelle.

Lernrate

- Die Lernrate gehört zu den zentralen Hyperparametern in der Optimierung Neuronaler Netze.
- Sie bestimmt die Schrittgröße, mit der das Modell die Gewichte während des Trainings aktualisiert.




Figure: Unterschiedliche Lernraten, Quelle.

Beispiel für lokale und globale Maxima und Minima




Figure: Unterschiedliche Lernraten, Quelle.




Figure: Darstellung der Lernfunktion, Quelle.

Regularisierung

- Ziel der Regularisierung ist es, die Verallgemeinerung des Modells auf unbekannte Daten zu verbessern.
- Es gibt verschiedene Methoden zur Regularisierung, darunter:
 - **Dropout:** Während des Trainings werden zufällig einige Neuronen und ihre Verbindungen deaktiviert, um Overfitting zu reduzieren.
 - **Early Stopping:** Der Trainingsprozess wird beendet, wenn die Modellgenauigkeit nach mehreren Iterationen nicht mehr steigt, um Overfitting und Underfitting zu vermeiden.

Beispiel für lokale und globale Maxima und Minima




Figure: Unterschiedliche Lernraten, **Quelle**.




Figure: Darstellung der Lernfunktion, **Quelle**.

Agenda

Einführung

Klassifikation

Lokalisierung

Objekterkennung

Bildsegmentierung

Deep Learning

Convolutional Neural Networks

Convolutional Neural Networks

- Convolutional Neural Networks (CNNs) sind spezialisierte Künstliche Neuronale Netze, die für Bildverarbeitung eingesetzt werden.
- Sie können Merkmale aus Bildern automatisch extrahieren und lernen.
- Ein typisches CNN besteht aus mehreren Schichten:
 - **Convolutional Layer** – Extrahiert Merkmale aus dem Bild.
 - **Pooling Layer** – Reduziert die Dimensionalität und hebt wichtige Informationen hervor.
 - **Fully Connected Layer** – Verarbeitet extrahierte Merkmale für die Klassifikation.
- CNNs können Bilder in verschiedene Regionen unterteilen und Objekte zuverlässig erkennen.

Convolutional Layer

- Der **Convolutional Layer** ist die erste Schicht eines CNNs und dient zur Extraktion von Merkmalen aus Bildern.
- Er besteht aus mehreren Filtern, deren Parameter festgelegt werden müssen:
 - **Anzahl der Filter** – Bestimmt, wie viele Merkmale extrahiert werden.
 - **Größe der Filter** – Legt fest, wie groß der Bereich ist, der analysiert wird.
 - **Stride** (Schrittweite) – Gibt an, wie weit der Filter pro Schritt über das Bild gleitet.
- Die Filter extrahieren Merkmale wie Kanten, Texturen und Formen aus den Bilddaten.
- Durch Faltung mit den Filtern wird die Bildgröße reduziert, was Speicherbedarf und Rechenaufwand verringert.

Convolutional Operator

- Der **Convolutional Operator** ist eine zentrale Technik in Convolutional Neural Networks (CNNs), die für Bilddaten eingesetzt wird.
- Dabei wird ein **Filter** (auch **Kernel** genannt) auf das Bild angewendet.
- Der Filter bewegt sich schrittweise von links nach rechts über das Bild.
 - Die Werte des Bildes werden mit den Werten des Filters multipliziert und aufsummiert.
 - Das Ergebnis dieser Berechnung wird in eine sogenannte **Feature Map** eingetragen.




Figure: Die Faltungsoperation, Quelle.

Pooling Layer

- In der **Pooling-Schicht** werden folgende Parameter festgelegt:
 - **Kernelgröße** – Gibt an, wie groß der Bereich ist, der zusammengefasst wird.
 - **Stride** (Schrittweite) – Bestimmt, wie weit sich das Fenster pro Schritt bewegt.
 - **Padding** – Kann verwendet werden, um die Dimension der Feature Map beizubehalten.
- Die **Padding-Schicht** sorgt dafür, dass die Ein- und Ausgabedimensionen gleich bleiben.
- Durch die Pooling-Schicht werden:
 - **Die Dimensionen reduziert**, wodurch der Rechenaufwand verringert wird.
 - **Relevante Informationen beibehalten**, während unwichtige Details entfernt werden.
- Arten von Pooling-Operationen:
 - **Max-Pooling** – Wählt den höchsten Wert innerhalb des Pooling-Kernels.
 - **Average-Pooling** – Berechnet den Durchschnitt der Werte im Pooling-Kernel.

Pooling Operator

- Die **Pooling-Operation** wird direkt nach der **Convolutional-Operation** angewendet.
- Ihr Hauptziel ist es, die **Dimension der Feature Map** zu reduzieren, während relevante Informationen erhalten bleiben.




Figure: Die MaxPooling-Operation, Quelle

Flattening Layer

- Die **Feature Maps** aus der letzten **Convolutional-Schicht** werden in einen eindimensionalen Vektor umgewandelt (**Flattening**).
- Dadurch können die extrahierten Merkmale in das **vollständig verbundene neuronale Netz** (*Fully Connected Layer*) eingespeist werden.
- Jeder Wert des geglätteten Vektors dient als Eingabe für die Neuronen der Fully Connected Layer.




Figure: Die Flatten-Operation, Quelle

CNN und Fully Connected Layer




Figure: Ein Convolutional Neuronales Netz, Quelle.

Projekt

- Im Rahmen dieses Moduls ist ein Projekt vorgesehen, das als Teil der Prüfungsleistung angerechnet wird.
- Das Projekt umfasst folgende Anforderungen:
 - **Datensatz:**
 - ◇ Ein geeigneter Datensatz muss ausgewählt werden.
 - ◇ Falls erforderlich, sollten die Bilddaten vorverarbeitet werden.
 - **Modell:**
 - ◇ Eine geeignete Architektur für ein **Convolutional Neural Network (CNN)** muss ausgewählt werden.
 - ◇ Das Modell muss trainiert und evaluiert werden. Dabei sollten verschiedene Konfigurationen von Hyperparametern getestet werden.
 - Die Ergebnisse der Modellgenauigkeit sollten zusammen mit den jeweiligen Hyperparameter-Kombinationen dokumentiert werden.
 - Ziel ist es, eine möglichst hohe Genauigkeit für das gegebene Klassifikationsproblem zu erreichen.

- **Google Colab** ist eine cloudbasierte Umgebung, die ähnlich wie ein **Jupyter Notebook** funktioniert.
- Der Code kann auf **CPU**, **GPU** oder **TPU** ausgeführt werden, um die Rechenleistung zu beschleunigen.
- Colab ermöglicht die Verbindung mit **Google Drive**, wodurch Speicherplatz und *RAM* geschont werden. Daten können direkt aus der Cloud geladen werden.
- Weitere Informationen unter: **Google Colab**.