

HOCHSCHULE HANNOVER
HSH AKADEMIE

IntoCode & InterGeeks

Maschinelles Lernen

EINFÜHRUNG IN DAS CLUSTERING

M.SC. BILAL AL HOMSI

HANNOVER, DEN 03.03.2025

Agenda

Arten des maschinellen Lernens

Unüberwachtes Lernen

Überwachtes Lernen

Arten des maschinellen Lernens

- Unüberwachtes Lernen
 - Clustering
 - ◇ K-means
 - ◇ DBSCAN
 - ◇ Hierarchisches Clustering
- Überwachtes Lernen
 - Klassifikation:
 - ◇ K-nearest neighbor KNN
 - ◇ Support Vector Machine SVM
 - ◇ Deep Learning: Künstliche Neuronale Netze
- Der Unterschied dazwischen ist, dass das überwachte Lernen gelabelte Daten nutzt, um Muster zu lernen und Vorhersagen zu treffen, während das unüberwachte Lernen ungelabelte Daten analysiert, um Strukturen oder Gruppen eigenständig zu erkennen.

Agenda

Arten des maschinellen Lernens

Unüberwachtes Lernen

Überwachtes Lernen

Unüberwachtes Lernen

- Beim unüberwachten Lernen werden Daten ohne Labels genutzt.
- Das Ziel ist es, Muster in den Daten zu finden.
- Clustering ist eine der Techniken des unüberwachten Lernens.
- Clustering ist eine Methode, um Daten in Gruppen zu unterteilen.
- Es gibt verschiedene Arten des Clustering, wie **K-Means**, **DBSCAN** und **Hierarchisches Clustering**.

K-Means Algorithmus

- K-Means ist eine Methode der Clusteranalyse, um Strukturen und Muster in unbekannten Daten zu finden.
- Der Algorithmus benötigt für das Clustering **Eingabedaten**, eine geeignete **Anzahl an Clustern**, denen die Daten zugeordnet werden können, und eine geeignete **Distanzfunktion** zur Ermittlung des Abstands zwischen zwei Datenpunkten. Das Verfahren terminiert nach so vielen Schritten dann, wenn es in der aktuellen Iteration keine Änderungen in den Clustern festgestellt werden.

Funktionen des K-Means Algorithmus

- Die Distanzfunktion $d(x, y)$ berechnet die Distanz zwischen zwei Punkten x und y .
- Es gibt verschiedene Arten von Distanzfunktionen:

- **Euklidische Distanz:**

$$d_{\text{euklidisch}}(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$


- **Manhattan-Distanz:**

$$d_{\text{manhattan}}(x, y) = \sum_{i=1}^n |x_i - y_i|$$

- **Maximale Distanz:**

$$d_{\text{maximal}}(x, y) = \max_{i=1}^n |x_i - y_i|$$

Methoden zur Ermittlung der Abstände zwischen zwei Punkten



- Euklidische Distanz:

$$= \sqrt{(X_1 - X_2)^2 + (Y_1 - Y_2)^2}$$


- Manhattan-Distanz:

$$= |X_1 - X_2| + |Y_1 - Y_2|$$


- Maximale Distanz:

$$= \max((|X_1 - X_2|) + (|Y_1 - Y_2|))$$


Euklidische Distanz






Manhattan Distanz



Maximale Distanz



Methoden zur Bestimmung der Abstände zwischen zwei Clustern



Single Linkage

- Der Abstand zwischen zwei Clustern wird als der kleinste Abstand zwischen einem Punkt im ersten Cluster und einem Punkt im zweiten Cluster definiert.
- Mathematisch ausgedrückt:

$$d(A, B) = \min\{d(x_i, x_j) \mid x_i \in A, x_j \in B\}$$

- Vorteil:
 - Kann lange, kettenartige Cluster (auch „chaining effect“) entdecken.
- Nachteil:
 - Kann empfindlich gegenüber Ausreißern sein.

Complete Linkage

- Der Abstand zwischen zwei Clustern wird als der größte Abstand zwischen einem Punkt im ersten Cluster und einem Punkt im zweiten Cluster definiert.
- Mathematisch ausgedrückt:

$$d(A, B) = \max\{d(x_i, x_j) \mid x_i \in A, x_j \in B\}$$

- Vorteil:
 - Weniger empfindlich gegenüber dem „chaining effect“.
- Nachteil:
 - Kleinste Gruppen können bevorzugt werden, da sie tendenziell eine größere Distanz zu anderen Punkten haben.

Average Linkage

- Der Abstand zwischen zwei Clustern wird als der mittlere Abstand zwischen allen Punktpaaren (einem aus dem ersten Cluster, einem aus dem zweiten Cluster) definiert.
- Mathematisch ausgedrückt:

$$d(A, B) = \frac{1}{|A||B|} \sum_{x_i \in A} \sum_{x_j \in B} d(x_i, x_j)$$

- Vorteil:
 - Bietet eine gute Balance zwischen den beiden vorherigen Methoden.
- Nachteile:
 - Kann bei sehr unterschiedlich großen Clustern nicht immer optimale Ergebnisse liefern.
 - Höherer Rechenaufwand als Single oder Complete Linkage.

Berechnung der Clusterzentren

- Nachdem jedem Datenpunkt ein Cluster zugewiesen wurde, werden die neuen Clusterzentren berechnet.
- Das neue Zentrum eines Clusters ist der Durchschnitt aller Datenpunkte, die diesem Cluster zugewiesen wurden.
- Mathematisch ausgedrückt:

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$



- Dabei ist μ_j das Zentrum des Clusters j , C_j die Menge der Datenpunkte im Cluster j , und x_i sind die Datenpunkte.

K-MeansAlgorithmus (Pseudocode)

- Input:
 - X: Datenpunkte, k: Anzahl der Cluster, $d(x, y)$: Distanzfunktion
- Output:
 - C: Clusterzentren
- Wähle die Anzahl der Cluster k.
- Wähle k zufällige Punkte als Clusterzentren.
- Weise jedem Datenpunkt den Cluster zu, dessen Zentrum am nächsten ist.
- Berechne die neuen Clusterzentren, indem der Durchschnitt der Datenpunkte in jedem Cluster berechnet wird.
- Wiederhole die Schritte 3 und 4, bis sich die Clusterzentren nicht mehr ändern.
- Die Clusterzentren sind die Ausgabe.

Beispiel für K-Means Clustering

$$\mathbf{X} = [(2, 10), (2, 5), (8, 4), (5, 8), (7, 5), (6, 4), (1, 2), (4, 9)], C = 3$$



Hierarchisches Clustering


- Hierarchisches Clustering ist eine Methode, um Daten in einer hierarchischen Struktur zu gruppieren.
- Es gibt zwei Arten des hierarchischen Clustering:
 - **Agglomeratives Clustering:**
Beim agglomerativen Clustering beginnt der Algorithmus mit jedem Datenpunkt als eigenem Cluster und fügt dann schrittweise die nächsten Cluster zusammen, bis alle Datenpunkte in einem Cluster sind.
 - **Divisives Clustering:**
Beim divisiven Clustering beginnt der Algorithmus mit allen Datenpunkten in einem Cluster und teilt dann schrittweise die Cluster auf, bis jeder Datenpunkt in einem eigenen Cluster ist.
- Der Algorithmus terminiert, wenn die gewünschte Anzahl an Clustern erreicht ist.

Agglomeratives Clustering

- Für dieses Verfahren benötigt man:
 - Eingabedaten (Datenpunkte) und Anzahl der Cluster
 - Distanzfunktion zur Berechnung der Distanz zwischen zwei Datenpunkten
 - Linkage-Methode zur Berechnung der Distanz zwischen zwei Clustern
- Der Algorithmus beginnt mit jedem Datenpunkt als eigenem Cluster.
- Die beiden Datenpunkte, die am nächsten beieinander liegen, werden zu einem Cluster zusammengeführt.
 - Wenn mehrere Punkte den gleichen Abstand haben, dann können zwei Punkte wahllos fusioniert werden.
- Um den Abstand zwischen zwei Clustern (Cluster hat mind. zwei Datenpunkte) zu bestimmen, wird eine der folgenden Methoden genutzt:
 - **Single Linkage, Complete Linkage, Average Linkage**
- Der Algorithmus terminiert, wenn die gewünschte Anzahl an Clustern erreicht ist.

Beispiel für Hierarchisches Clustering

- Gegeben ist folgender Datensatz:
 - $\mathbf{X} = [(2, 1), (5, 1), (1, 2), (2, 2), (4, 2), (2, 3), (4, 4), (5, 4), (4, 5), (5, 5)]$
- Trage alle Datenpunkte in ein Koordinatensystem ein.
- Berechne die Distanz zwischen den Punkten.
 - **Maximale Distanz**
- Berechne die Distanz zwischen den Clustern.
 - **Single Linkage**



Beispiel für Hierarchisches Clustering

	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10
P1	0									
P2	3	0								
P3	1	4	0							
P4	1	3	1	0						
P5	2	1	3	2	0					
P6	2	3	1	1	2	0				
P7	3	3	3	2	2	2	0			
P8	3	3	4	3	2	3	1	0		
P9	4	4	3	3	3	2	1	1	0	
P10	4	4	4	3	3	3	1	1	1	0

- Die Abkürzung steht für ”**Density-Based Spatial Clustering of Applications with Noise**”. Dieses Verfahren bietet im Vergleich zu anderen Clusterverfahren eine dichtbasierte Clusteranalyse. Das heißt, dass Rauschpunkte im Datensatz leicht eliminiert werden können.
- Der Algorithmus basiert auf der Annahme, dass Cluster in den Datenpunkten dichter sind als der Rest der Datenpunkte.
- Bei diesem Verfahren werden sowohl ein Radius ϵ als auch die Anzahl an benachbarten Datenpunkte **K** vordefiniert.
- Arten der Datenpunkte:
 - **Kernpunkte:** Punkte, die mindestens K Nachbarn innerhalb des Radius ϵ haben.
 - **Randpunkte:** Punkte, die weniger als K Nachbarn innerhalb des Radius ϵ haben, aber von einem Kernpunkt erreicht werden können.
 - **Rauschpunkte:** Punkte, die weder Kern- noch Randpunkte sind.



DBSCAN Algorithmus

- Es wird bei einem Datenpunkt gestartet und bestimmt, ob dieser die vordefinierte Anzahl an Nachbarn hätte. Diese liegen innerhalb des Kreises mit dem vordefinierten Radius.
- Die Kernpunkte werden iterativ markiert.
- Es wird bei einem Kernpunkt gestartet und geprüft, ob seine Nachbarn auch Kernpunkte sind. Diese werden einem Cluster zugeordnet, bis die Kernpunkte abgearbeitet sind.
- Diese Vorgehensweise wird iterativ durchgeführt, bis alle Kernpunkte im Datensatz einem eindeutigen Cluster zugeordnet sind.



DBSCAN Algorithmus

- Die Randpunkte werden dem jeweiligen Cluster zugeordnet, aber nicht weiter betrachtet oder expandiert. Sie stellen quasi die Außengrenze eines Clusters dar.
- Alle übrigen Punkte werden als Rauschpunkte betrachtet und eliminiert.
- Dieses Verfahren ist zwar aufwändiger als andere Clusterverfahren, aber liefert präzise Ergebnisse.
- Es wird hauptsächlich für Spirale Datensätze verwendet. Das heißt, es wird für Datenpunkte verwendet, die nicht linear trennbar sind.



Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering





Beispiel für DBSCAN Clustering




Beispiel für DBSCAN Clustering




Beispiel für DBSCAN Clustering




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel




Beispiel



Beispiel



Beispiel



Agenda

Arten des maschinellen Lernens

Unüberwachtes Lernen

Überwachtes Lernen

Überwachtes Lernen

- Beim überwachten Lernen werden Daten mit Labels genutzt.
- Das Ziel ist es, ein Modell zu erstellen, das die Daten klassifizieren kann.
- Klassifikation ist eine der Techniken des überwachten Lernens.
- Klassifikation ist eine Methode, um Daten nach Kategorien zu klassifizieren.
- Es gibt verschiedene Arten des überwachten Lernens, wie **K-nearest neighbor KNN**, **Support Vector Machine SVM**, **lineare Regression** und **Deep Learning**.
- Der Unterschied zum unüberwachten Lernen ist, dass beim überwachten Lernen Daten mit Labels genutzt werden.

K-nearest neighbor KNN

- K-nearest neighbor (KNN) ist ein überwachtes Klassifikationsverfahren, das unbekannte Datenpunkte anhand der **K** nächsten Nachbarn einer Klasse zuordnet.
- Zur Ermittlung der Abstände zwischen dem neuen Datenpunkt und den übrigen Punkten wird häufig die **euklidische Distanz** verwendet, aber auch andere Metriken wie die Manhattan-Distanz sind möglich.
- Zur Klassifikation werden die **K** nächstgelegenen Datenpunkte betrachtet, also jene mit den kleinsten Abständen zum neuen Datenpunkt.
- Die Klassenzuordnung erfolgt nach dem Mehrheitsprinzip: Der neue Datenpunkt wird der Klasse zugeordnet, die unter den **K** nächsten Nachbarn am häufigsten vertreten ist.

K-nearest neighbor (KNN) Algorithmus

- **Input:**

- X : Menge der Datenpunkte
- k : Anzahl der nächsten Nachbarn


- **Output:**

- C : Zugeordnete Klasse der Datenpunkte

- Wähle die Anzahl der Nachbarn k .
- Berechne die Distanz zwischen dem zu klassifizierenden Punkt und allen anderen Datenpunkten.
- Wähle die k nächsten Nachbarn.
- Weise dem Punkt die Klasse zu, die unter den k Nachbarn am häufigsten vorkommt (Mehrheitsprinzip).
- Der Algorithmus gibt die vorhergesagte Klasse für jeden Datenpunkt aus.


Beispiel für K-nearest neighbor KNN

- Gegeben ist eine Klassenverteilung von geclusterten Datenpunkten.
- Es gibt einen neuen Datenpunkt, der einer der gegebenen Klassen zuzuordnen werden soll.




Beispiel für K-nearest neighbor KNN

- Dafür werden die Abstände zwischen dem neuen Datenpunkt und allen übrigen Datenpunkten. Diese werden mit der Formel der **euklidischen Distanz** bestimmt.




Beispiel für K-nearest neighbor KNN

- Für dieses Beispiel sei **K=3**.
- Die drei nächsten Nachbarn des neuen Datenpunktes sind die Datenpunkte, die die kürzesten Abstände zum neuen Datenpunkt haben.
- Von der Klasse **B** wurden zwei Datenpunkte und von der Klasse **A** einen Datenpunkt ermittelt.
- **Max(A=1,B=2) = B**



Beispiel für K-nearest neighbor KNN

- Der neue Datenpunkt wird somit der Klasse **B** zugeordnet.




Support Vector Machine SVM

- Support Vector Machine SVM ist ein lineares Modell im überwachten Lernen.
- Der Algorithmus basiert auf der Annahme, dass die Datenpunkte in einem höherdimensionalen Raum linear separierbar sind.
- SVM wird zur binären Klassifikation verwendet.
- Der Algorithmus benötigt für die Klassifikation **Eingabedaten** und die **Anzahl der Klassen** die sogenannten **Labels**, die zur Klassifikation genutzt werden sollen.
- Es gibt verschiedene Arten von SVM:
 - **Linear**
 - **Nichtlinear**
- Mit dem Linearem SVM werden gelabelte Datenpunkte linear separiert.


Welche Trennung ist besser?

- Das Ergebnis der Klassifizierung eines neuen Datenpunktes hängt von der Trennung der Datenpunkte.
- Die Trennung der Datenpunkte erfolgt durch verschiedene Linien.
- Es ist wichtig, dass eine optimale Trennlinie gefunden wird.
- Die optimale Trennlinie stellt die größtmögliche Distanz zwischen den Datenpunkten dar.
- Neue Datenpunkte werden anhand dieser Trennung klassifiziert.



Der Margin-Bereich und die Hyperebene


- Um die optimale Trennline zu finden, werden die sogenannten **Support Vektoren** verwendet.
- Support Vektoren repräsentieren Datenpunkte, die den Bereich (**Margin**) zwischen den zwei Klassen **maximieren**.
- Die optimale Trennline wird als **Hyperebene** bezeichnet.
- Der Margin-Bereich ist der Maximale Abstand zwischen den Klassen.




Lineare Regression

- Lineare Regression ist eine Methode des überwachten Lernens, um Daten zu klassifizieren.
- Ein statistisches Modell zur Vorhersage einer Zielvariablen anhand einer Eingangsvariablen.
- Sie findet die beste Gerade, die die Daten beschreibt.
- Die Gerade wird so gewählt, dass die Summe der quadrierten Fehler bzw. Abweichungen der Datenpunkte von der Geraden minimal ist.
- Der Unterschied zur Klassifizierung ist, dass die Zielvariable kontinuierlich ist, während sie bei der Klassifizierung diskret ist.

Lineare Regression



Nichtlinear Trennbare Datenpunkte 2D



Linear Trennbare Datenpunkte 3D

- Um die Datenpunkte linear zu trennen, wird ein sogenannter **Kernel Trick** verwendet.
- Die Idee ist, dass Datenpunkte in einen **höherdimensionalen Raum** transformiert werden, um sie dort linear zu separieren.

Linear trennbare Daten in höherer Dimension

